

Regresión Lineal: recolección de datos y modelado de produccion_toneladas

Taller: Semana 4 – Herramientas de recolección de datos

Curso: Machine Learning

Autores: Cristian Alejandro Perdomo Rivas

Fecha: 19/09/2026

Proyecto de regresión lineal con Python (pandas, scikit-learn) sobre datos de producción de
frutales en el Valle del Cauca.

1 Resumen ejecutivo

Este informe documenta la recolección, limpieza, modelado y evaluación de un modelo de regresión lineal que estima la variable continua `produccion_toneladas` (toneladas de fruta producidas) a partir de tres predictores: `año`, `id_municipio` y la variable categórica `subregion`. Los datos provienen de un conjunto abierto de producción de frutales en el Valle del Cauca (Colombia) y, para evitar mezclar especies distintas, el análisis se restringe al cultivo con más registros, el plátano (943 filas tras limpiar). El modelo, ajustado con `LinearRegression` de `scikit-learn` sobre una partición 80/20 con semilla 42, obtiene en test $R^2 = 0.1909$ y $RMSE = 8249.39$ toneladas. La conclusión principal es que el modelo explica alrededor del 19% de la varianza: la relación lineal de los predictores disponibles con la producción es débil y el objetivo está fuertemente sesgado, por lo que el modelo sirve como línea base más que como predictor preciso.

2 Método de recolección

2.1 Fuente y tipo

Los datos proceden de un conjunto de datos abiertos (*open data*) con registros de producción de frutales en el Valle del Cauca (Colombia). El archivo fuente es un CSV con campos delimitados por comas y entrecomillados. La tabla 1 resume su trazabilidad.

Cuadro 1: Trazabilidad del conjunto de datos original.

Campo	Valor
Fuente	Registros de producción de frutales en el Valle del Cauca (Colombia)
URL	https://www.datos.gov.co/browse?q=venta+&sortBy=relevance&pageSize=20
Fecha de obtención	2026-09-19
Formato	CSV (campos entre comillas; decimal con coma)
Filas	9992
Columnas	8

2.2 Pasos de recolección

Los pasos seguidos en el *notebook* `01_recoleccion.ipynb` fueron:

1. Se identificó el archivo fuente en `./files/`.
2. Se copió, sin modificar, a `data/raw/` con `shutil.copy2`.
3. Se leyó con `pandas` usando separador por comas y comillas (`sep=','`).
4. Se revisó la estructura: nombres de columna, forma del dataset y primeras filas.
5. Se aplicaron criterios de calidad (nulos, duplicados, tipos y rangos).

2.3 Criterios de calidad revisados

Sobre el archivo original de 9992 filas y 8 columnas se verificaron los siguientes criterios:

- **Nulos:** 0 valores nulos en todas las columnas.
- **Duplicados:** 39 filas duplicadas exactas (se eliminan en la limpieza).

- **Tipos de dato:** al leer, `año`, `Id_municipio` e `Id_cultivo` se interpretan como enteros; `Produccion_toneladas` queda como texto y debe convertirse a número.
- **Rangos razonables:** el año va de 2000 a 2022; la producción usa formato español (punto como separador de miles y coma decimal); hay 202 registros con producción igual a cero y ninguno negativo; `subregion` tiene 4 categorías, `ciclo` 3, `cultivo` 38 y `municipio` 42.

El dataset cubre 38 cultivos y 42 municipios. Para este taller se seleccionó únicamente el cultivo **plátano**, por ser el de mayor número de registros (943 filas). Tras el filtro, las columnas `cultivo`, `id_cultivo` y `ciclo` quedan constantes (para el plátano el ciclo es siempre *Anual*) y se descartan junto con `municipio` (texto duplicado del identificador). El dataset limpio final tiene 943 filas y 4 columnas y se guarda en `data/processed/frutales_limpias.csv`.

3 Análisis exploratorio

3.1 Diccionario de variables

La tabla 2 describe las variables del dataset limpio.

Cuadro 2: Diccionario de variables del dataset limpio.

Variable	Descripción	Tipo	Rol
<code>produccion_toneladas</code>	Toneladas de fruta producidas	numérica (float)	Objetivo
<code>año</code>	Año del registro (2000–2022)	numérica (int)	Predictor
<code>id_municipio</code>	Identificador numérico del municipio	numérica (int)	Predictor
<code>subregion</code>	Región geográfica (Centro, Norte, Pacífico, Sur)	categorica	Predictor

3.2 Estadísticos descriptivos

La tabla 3 resume las variables numéricas. La variable categórica `subregion` presenta 4 categorías, siendo *Norte* la más frecuente con 368 registros.

Cuadro 3: Estadísticos descriptivos de las variables numéricas (n = 943).

Variable	Media	Desv.	Mín.	P25	Mediana	P75	Máx.
<code>produccion_toneladas</code>	5346.90	9997.69	33	775	1978	4771	105000
<code>año</code>	2010.88	6.65	2000	2005	2011	2017	2022
<code>id_municipio</code>	76414	300	76001	76126	76364	76670	76895

La distribución de la producción (Figura 1) es fuertemente asimétrica hacia la derecha: la mediana es 1978 t mientras que el máximo alcanza 105 000 t. Esto implica que unos pocos valores extremos dominan la escala y anticipan que los residuos del modelo no serán simétricos.

3.3 Correlación

La matriz de correlación de las variables numéricas (Figura 2) muestra correlaciones débiles entre todas las parejas. La más alta con el objetivo la presenta `año`, con $r = 0.171$ (valor reportado por el *notebook* 04); el resto de correlaciones son aún menores. Esto sugiere que la relación lineal entre los predictores disponibles y la producción es limitada.

3.4 Relación de cada predictor con el objetivo

La Figura 3 muestra la relación de cada predictor con la producción: las variables numéricas (`año` e `id_municipio`) como diagramas de dispersión y la categórica (`subregion`) como diagrama de




Figura 1: Distribución de la variable objetivo (transformación $\log_{1p}$ para visualizar el sesgo).




Figura 2: Matriz de correlación de las variables numéricas.

cajas. No se observa una tendencia lineal clara en ningún caso; las medianas de producción son parecidas entre subregiones.




Figura 3: Relación de cada predictor con la variable objetivo.

4 Modelo

4.1 Configuración

El modelo se ajustó en el *notebook* 03_modelo.ipynb con la siguiente configuración:

- **Partición:** `train_test_split` con 80% de entrenamiento (754 filas) y 20% de prueba (189 filas); `test_size=0.2` y `random_state=42`.
- **Tratamiento de categóricas:** la variable `subregion` (4 categorías) se codificó con `pd.get_dummies(drop_first=True)`, generando 3 variables binarias (`subregion_Norte`, `subregion_Pacifico`, `subregion_Sur`) y dejando `Centro` como categoría base.
- **Variables usadas:** `año`, `id_municipio` y los dummies de `subregion`. Se justifican porque describen cuándo, dónde y en qué subregión se produce; el cultivo se fija a plátano para eliminar el efecto de la especie.
- **Algoritmo:** `LinearRegression` de `scikit-learn`.

4.2 Coeficientes e intercepto

La tabla 4 presenta los coeficientes estimados. El intercepto no tiene una interpretación práctica directa (es el valor predicho cuando todos los predictores valen cero, lo que obliga a extrapolar

la recta de la variable **año** hasta el año 0). Los coeficientes con mayor magnitud son los de **subregion**: respecto a la base **Centro**, la subregión **Pacífico** se asocia con -7881.80 t y **Sur** con -7111.30 t, mientras que **Norte** aporta -4302.00 t. La variable **año** aporta $+240.59$ t por cada año adicional, y **id_municipio** tiene un efecto despreciable ($+0.45$ t por unidad de código).

Cuadro 4: Coeficientes e intercepto del modelo de regresión lineal.

Variable	Coeficiente
Intercepto (b_0)	-509200.34
año	240.59
id_municipio	0.45
subregion_Norte	-4302.00
subregion_Pacífico	-7881.80
subregion_Sur	-7111.30

4.3 Validación de supuestos

4.3.1 Linealidad

La linealidad se revisa con el gráfico de residuos frente a predicciones (Figura 4). Los residuos no muestran un patrón curvo claro, sino una nube alrededor de cero dominada por unos pocos puntos extremos (grandes residuos negativos para las producciones altas, que el modelo subestima). El supuesto de linealidad se cumple **parcialmente**.




Figura 4: Residuos frente a predicciones (linealidad y homocedasticidad).

4.3.2 Homocedasticidad

En el mismo gráfico (Figura 4) se observa que la dispersión vertical no es constante: los residuos extremos concentran la mayor parte de la varianza y generan una forma de embudo. Además, al ser los predictores débiles, las predicciones se agrupan en un rango pequeño. El supuesto de homocedasticidad **no se cumple** (heterocedasticidad).

4.3.3 Distribución de los residuos

El histograma (Figura 5, con transformación $\text{signo} \cdot \log(1 + |r|)$ para comprimir los extremos) y el gráfico Q-Q (Figura 6) muestran que los residuos tienen colas pesadas y se desvían de la normal en los extremos. El supuesto de normalidad **no se cumple**, algo esperable dado el sesgo del objetivo.




Figura 5: Histograma de los residuos (transformación $\text{signo} \cdot \log1p$).




Figura 6: Gráfico Q-Q de los residuos.

5 Evaluación

La tabla 5 resume las métricas calculadas sobre el conjunto de prueba (189 observaciones).

Cuadro 5: Métricas de error sobre el conjunto de prueba.

Métrica	Valor
MAE	4838.09
MSE	6.81×10^7
RMSE	8249.39
R^2	0.1909

El MAE y el RMSE están en las mismas unidades que el objetivo (toneladas). Un RMSE de 8249.39 t es grande frente a la mediana de la producción (1978 t), lo que refleja que el error está inflado por los valores extremos. El $R^2 = 0.1909$ indica que el modelo explica alrededor del 19% de la varianza de la producción en test, un poder predictivo modesto pero coherente con las correlaciones débiles observadas en el EDA.

La Figura 7 compara valores reales y predichos frente a la recta $y = x$; los puntos se alejan de la diagonal, sobre todo en los valores altos. La Figura 8 muestra la recta de regresión del predictor numérico más correlacionado (año, $r = 0.171$), con una pendiente positiva débil. Finalmente, la Figura 9 confirma el patrón de residuos ya comentado.




Figura 7: Valores reales frente a predichos, con la recta $y = x$.

6 Conclusiones y trabajo futuro

6.1 Hallazgos

El modelo lineal explica el 19.09% de la varianza de la producción en test, con un RMSE de 8249.39 t. La relación entre los predictores y el objetivo es débil, y la producción está dominada por unos pocos valores muy grandes que el modelo no logra capturar.




Figura 8: Dispersión y recta de regresión del predictor más correlacionado (año).




Figura 9: Residuos frente a predicciones en el conjunto de prueba.

6.2 Variables más relevantes

Por magnitud de coeficiente, las variables más relevantes son las categorías de **subregion** (en particular **Pacifico**, -7881.80 t respecto a **Centro**), seguidas de **año** ($+240.59$ t por año). **id_municipio** tiene un efecto despreciable.

6.3 Sesgos y limitaciones

- **id_municipio** se trató como variable numérica, aunque es un código categórico.
- El análisis se limita a un solo cultivo (plátano), por lo que no generaliza a otros frutales.
- La producción está muy sesgada a la derecha (mediana 1978 t frente a un máximo de 105 000 t), lo que viola los supuestos de homocedasticidad y normalidad.
- El modelo solo dispone de tres predictores; variables como el cultivo (38 categorías) se descartaron por granularidad, perdiendo información.

6.4 Mejoras futuras

- Modelar el logaritmo de la producción (transformación $\log_{1p}$) para reducir el sesgo y estabilizar la varianza.
- Incorporar el cultivo como variable categórica (con codificación adecuada) en lugar de filtrar a un único cultivo.
- Probar modelos no lineales (por ejemplo, árboles de decisión).
- Documentar la URL de la fuente y repetir el análisis por subregión.

7 Repositorio GitHub

El repositorio del proyecto se encuentra en el siguiente enlace:

<https://github.com/CAlejandroPerdomo/UDEC-Regresion-Lineal>

La estructura de carpetas es la siguiente:

```
.
|-- data/
|   |-- raw/                # archivo original, sin modificar
|   |-- processed/          # dataset limpio (frutales_limpias.csv)
|-- notebooks/
|   |-- 01_recoleccion.ipynb
|   |-- 02_eda.ipynb
|   |-- 03_modelo.ipynb
|   |-- 04_evaluacion.ipynb
|-- figures/                 # graficos en PNG
|-- requirements.txt
-- README.md
```